# レーティング予測によるフォントを基盤としたレビュー解析

豊田工業大学 知能数理研究室 外山 洋太, 三輪 誠, 佐々木 裕

#### 背景と目的

- ▶ 対象タスク:表意,表語文字を含む言語におけるレーティング予測
- ▶ 応用例:企業における文書からの商品の評判分析
- ▶ 目的:文字の表層情報を利用したレーティング予測の実現




表語文字: 1文字で1語を表現 快情悩鯛鱒鯵

表意文字: 1文字で意味を表現



#### 提案手法

- ▶ 入力:フォント画像で表現されたレビュー
- ▶ 出力:予測したレーティングラベル
- ▶ 特徴
  - ▶ フォント 画像から文字の意味情報を抽出
  - ▶ HAN[1] の手法を基に文字からの文書の階層構造を利用
- ▶ 予測過程
  - (1) 畳み込み NN (LeNet) によりフォント 画像を文字埋め込みを生成
  - (2) 文字から単語、単語から文、文から文書へ階層的に Gated Recurrent Unit (GRU) による RNN を用いて埋め込みを生成
  - (3) 文書埋め込みからラベルを予測



▶ アテンション構造 [1]

$$u_{i} = \tanh(Wh_{i} + b)$$

$$\alpha_{i} = \frac{\exp(u_{i}^{T}u_{context})}{\sum_{i} \exp(u_{i}^{T}u_{context})}$$

$$\hat{h} = \sum_{i} \alpha_{i}h_{i}$$

( u<sub>context</sub> : 文脈ベクトル

 $\alpha_i$ : アテンション

h;: 下の階層の埋め込み

ĥ: 上の階層の埋め込み

W, b:線形層のパラメータ

#### 関連研究

- ► Hierarchical Attention Network (HAN) [1]
  - ► Attention 構造付きの Recurrent Neural Network (RNN) を用いた文書分類モデル
  - ▶ 文字または単語から文,文書までの階層的構造を利用
  - → 文字の表層情報の利用ができていない
- ► Radical-Enhanced Chinese Character Embedding [2]
  - ▶ 漢字-部首辞書を利用した漢字埋め込みの生成手法
  - ▶ 対象タスクと漢字の部首当てについて同時に学習
  - → 漢字-部首辞書が余分に必要

#### 予備実験

- ▶ 実験設定
  - ▶ 7カテゴリにおける 0~5点のレーティング予測
  - ▶ データセット:楽天トラベルのレビュー 330,000件
- ▶ 結果▶ 従来手法より高い正答率提案手法□ 正答率○ .503○ .524
- ▶ 高いアテンションが付く表現
  - ▶ 「食」,「部屋」,「風呂」等のカテゴリを表すもの
  - ▶ 「広」,「満」,「広」,「悪」等の評価を表すもの
  - ▶ 「は」,「が」,「も」等の助詞

#### クチコミ 通り 大変 料理 が 美味しか た です。

期待以上の宿でした。

またお世話になりたいと思います。

レビューのアテンション例 (1)

## とても広い部屋で大満足でした。

同行したみんなも満足でした。

レビューのアテンション例 (2)

### まとめ

- ▶ フォント 画像を用いたレーティング予測及びレビュー解析の手法を提案
- ▶ 提案手法による従来手法 [1] より高い正答率
- ▶ アテンションの可視化によるレビューの解析
- ▶ 今後の予定
  - ▶ フォント画像に対するアテンションの可視化の実装

#### 参考文献

- [1] Zichao Yang et al., Hierarchical Attention Networks for Document Classification. NAACL 2016. 2016.
- [2] Yaming Sun et al., Radical-Enhanced Chinese Character Embedding. ICONIP 2014, 2014.
- [3] 外山洋太ら, 文書・文間及びカテゴリ間の関係を考慮したレーティング予測. 豊田工業大学 学士論文.